

# Laboratorium: Klasyfikacja i regresja w Keras

May 14, 2024

## 1 Zakres ćwiczeń

- Przypomnienie zasad budowy prostych sieci neuronowych dla klasyfikacji oraz regresji.
- Budowanie sieci przy pomocy API Sequential Keras.
- Zbieranie danych procesu uczenia i jego wizualizacja przy pomocy TensorBoard.
- Korzystanie z mechanizmu *early stopping* do zatrzymania procesu uczenia w odpowiednim czasie.

## 2 Zadania

### 2.1 Klasyfikacja obrazów


Pobierz zbiór danych *Fashion MNIST*.

```
import tensorflow as tf
fashion_mnist = tf.keras.datasets.fashion_mnist
(X_train, y_train), (X_test, y_test) = fashion_mnist.load_data()
assert X_train.shape == (60000, 28, 28)
assert X_test.shape == (10000, 28, 28)
assert y_train.shape == (60000,)
assert y_test.shape == (10000,)
```

Przeskaluj wartości z zakresu 0–255 do zakresu 0–1.

Wyświetl przykładowy rysunek używany do klasyfikacji:

```
import matplotlib.pyplot as plt
plt.imshow(X_train[2137], cmap="binary")
plt.axis('off')
plt.show()
```



Utwórz listę nazw kategorii zgodnie ze specyfikacją zbioru danych:

```
class_names = ["koszulka", "spodnie", "pulower", "sukienka", "kurtka",  
               "sandał", "koszula", "but", "torba", "kozak"]  
class_names[y_train[2137]]
```

'sukienka'

Stwórz model sekwencyjny zawierający warstwy gęste:

- warstwę spłaszczającą dane, tj. przekształcającą z postaci (28,28) do postaci (784),
- warstwę ukrytą zawierającą 300 neuronów,
- warstwę ukrytą zawierającą 100 neuronów,
- warstwę wyjściową odpowiednią dla problemu klasyfikacji przy 10 klasach.

Wyświetl podsumowanie i graficzną reprezentację struktury sieci.

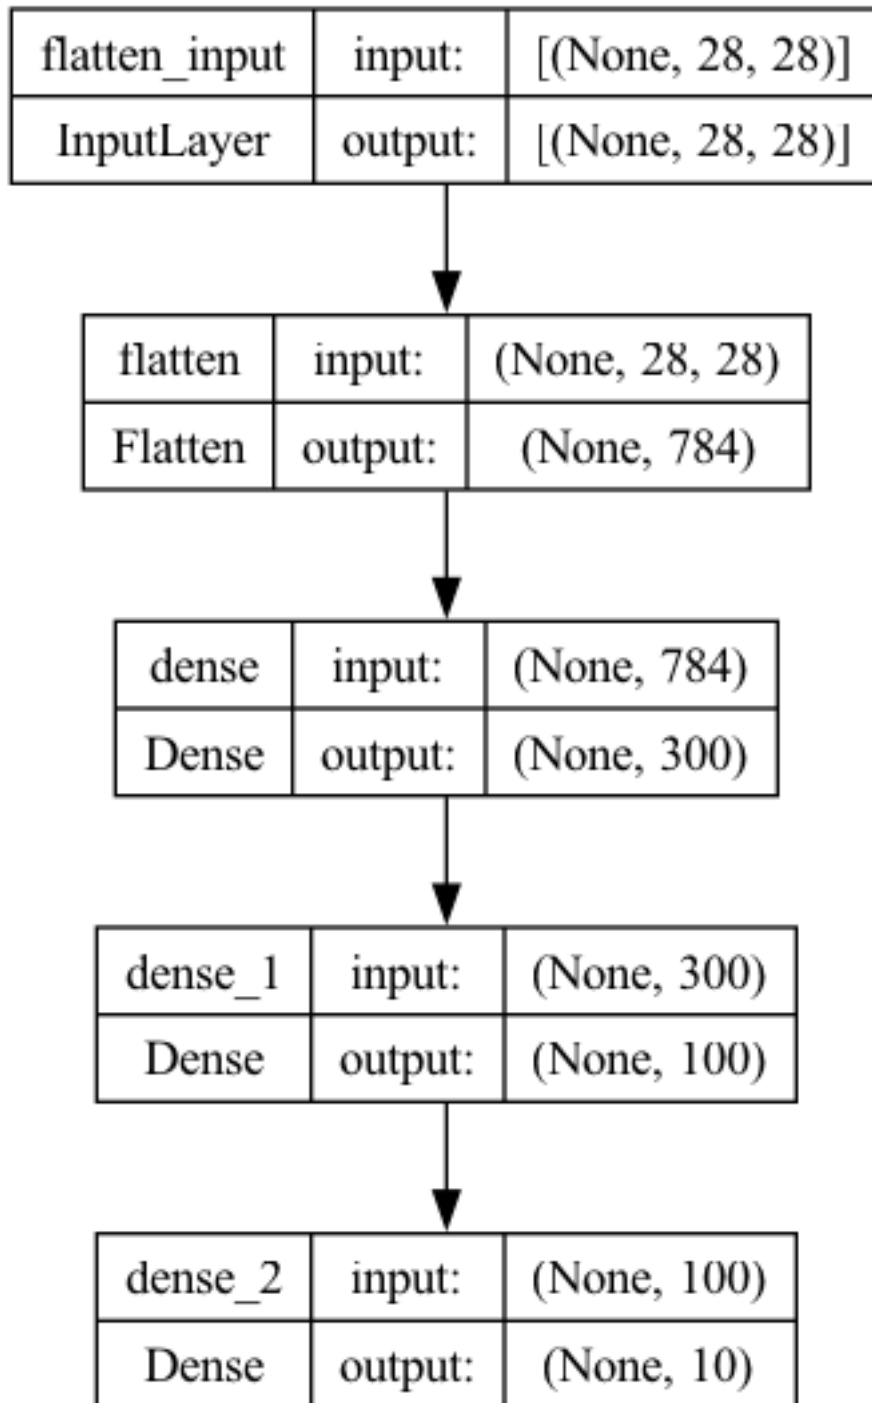
```
model.summary()  
tf.keras.utils.plot_model(model, "fashion_mnist.png", show_shapes=True)
```

Model: "sequential"

Layer (type)	Output Shape	Param #
flatten (Flatten)	(None, 784)	0

dense (Dense)	(None, 300)	235500
dense_1 (Dense)	(None, 100)	30100
dense_2 (Dense)	(None, 10)	1010

```
=====
Total params: 266610 (1.02 MB)
Trainable params: 266610 (1.02 MB)
Non-trainable params: 0 (0.00 Byte)
-----
```



Skompiluj model, podając [rzadką entropię krzyżową](#) jako funkcję straty, SGD jako optymalizator i [dokładność](#) jako metrykę.

Przygotuj [callback Tensorboard](#) do zbierania historii uczenia w katalogu `image_logs`, będącym podkatalogim bieżącego katalogu. Możesz użyć do tego funkcji, która przy każdym wywołaniu

będzie zwracała nową nazwę katalogu, opartą o aktualny czas. Alternatywnie możesz nadawać katalogom nazwy związane np. z parametrami danego eksperymentu. Pamiętaj, że TensorBoard po uruchomieniu zawsze szuka w podanym katalogu podkatalogów odpowiadających kolejnym procesom uczenia sieci.

Przyucz model przez 20 epok. Wykorzystaj 10% zbioru uczącego jako zbiór walidacyjny – zwróć uwagę że, w odróżnieniu od przykładu z wykładu czy podręcznika, nie został on wcześniej wydzielony ręcznie. Pamiętaj o dołączeniu callbacku TensorBoard.

Wykonaj kilka przykładowych predykcji dla losowych elementów zbioru testowego. Czy podpisy odpowiadają zawartości obrazków?

```
image_index = np.random.randint(len(X_test))
image = np.array([X_test[image_index]])
confidences = model.predict(image)
confidence = np.max(confidences[0])
prediction = np.argmax(confidences[0])
print("Prediction:", class_names[prediction])
print("Confidence:", confidence)
print("Truth:", class_names[y_test[image_index]])
plt.imshow(image[0], cmap="binary")
plt.axis('off')
plt.show()
```

1/1 [=====] - 0s 14ms/step

Prediction: sandał

Confidence: 0.99815553

Truth: sandał



Przeanalizuj proces uczenia uruchamiając TensorBoard. Możesz to zrobić albo uruchamiając jego proces w Terminalu

```
$ tensorboard --logdir=./image_logs --port=6006
```

i otwierając jego interfejs przy pomocy odpowiedniego adresu w przeglądarce, lub korzystając z rozszerzenia Jupytera, najpierw ładując samo rozszerzenie:

```
%load_ext tensorboard
```

i następnie uruchamiając sam TensorBoard:

```
%tensorboard --logdir ./image_logs
```

Zapisz model w pliku `fashion_clf.keras`.

**6 punktów**

## 2.2 Regresja

Pobierz zbiór danych California Housing z pakietu scikit-learn:

```
from sklearn.datasets import fetch_california_housing
from sklearn.model_selection import train_test_split
from sklearn.preprocessing import StandardScaler

housing = fetch_california_housing()
```

Podziel zbiór na uczący, walidacyjny i testowy. Tym razem ręcznie wydziel zbiór walidacyjny (`train_test_split`) i nie korzystaj z argumentu `validation_split` metody `fit`.

Utwórz model, zawierający:

- warstwę normalizującą wartości cech,
- 3 warstwy po 50 neuronów,
- warstwę wyjściową odpowiednią do regresji pojedynczej wartości.

Skompiluj go używając błędu średniokwadratowego jako funkcji straty i optymalizatora Adam, wyliczając dodatkowo RMSE jako metrykę. Pamiętaj o skalibrowaniu warstwy normalizacyjnej.

Przygotuj callback *early stopping* o cierpliwości równej 5 epok, minimalnej wartości poprawy wynoszącej 0.01 i włączając wyświetlanie komunikatów o przerwaniu uczenia na ekranie.

Podobnie jak w poprzednim ćwiczeniu, przygotuj callback Tensorboard, tak aby zbierał logi do katalogu `housing_logs`.

Przeprowadź uczenie modelu korzystając z obu callbacków (*early stopping* i TensorBoard). Jaką liczbę epok uczenia należy podać w tym przypadku?

Zapisz model w pliku `reg_housing_1.keras`.

Utwórz jeszcze co najmniej dwa modele o innej strukturze – poeksperymentuj z liczbą warstw oraz liczbą jednostek na jednej warstwie. Zapisz je w plikach `reg_housing_2.keras`, `reg_housing_3.keras`, itd. Zapisuj logi TensorBoard w kolejnych podkatalogach katalogu `housing_logs`.

**6 punktów** (po 2 za każdy z modeli)

Uruchom TensorBoard i porównaj przebieg procesu uczenia w zależności od dobranych parametrów.

### 3 Wyślij rozwiązanie

Umieść skrypt realizujący powyższe ćwiczenia w pliku `lab09/lab09.py`.

Pamiętaj o przetestowaniu skryptu i upewnieniu się, że jest w stanie poprawnie pracować w trybie wsadowym i nie zawiera żadnych poleceń działających tylko w środowisku IPython/Jupyter.